PENERAPAN LONG SHORT-TERM MEMORY DALAM PERAMALAN NILAI EKSPOR NONMIGAS

Laporan Individu Kegiatan Magang
Di Direktorat ASDIPI, Ditjen KPAII, Kementerian Perindustrian

SANDRA BERLIANA PUTRI
G1401221021

PROGRAM STUDI STATISTIKA DAN SAINS DATA
SEKOLAH SAINS DATA, MATEMATIKA, DAN INFORMATIKA
INSTITUT PERTANIAN BOGOR
BOGOR
2025

ABSTRAK

SANDRA BERLIANA PUTRI. Penerapan Long Short-Term Memory dalam Peramalan Nilai Ekspor Nonmigas. Dibimbing oleh CYNTHIA KURNIAWATI HINDARTO dan AGUS MOHAMAD SOLEH.

Peramalan nilai ekspor nonmigas Indonesia penting untuk mendukung strategi perdagangan dan kebijakan industri. Penelitian ini bertujuan meramalkan nilai ekspor nonmigas hingga Desember 2026 menggunakan model *Long Short-Term Memory* (LSTM). Data yang digunakan adalah data bulanan periode Januari 2005 hingga Juli 2025. Hasil penelitian menunjukkan model LSTM mampu menangkap pola nilai ekspor nonmigas secara akurat, dengan MAPE data latih dan uji berada pada kategori sangat baik tanpa indikasi *overfitting*. Peramalan hingga Desember 2026 mengindikasikan tren penurunan nilai ekspor secara bertahap. Temuan ini memberikan dasar yang dapat digunakan oleh pemerintah dan pelaku usaha dalam menyusun strategi ekspor yang lebih adaptif dan berbasis prediksi.

Kata kunci: ekspor nonmigas, *hyperparameter*, LSTM, MAPE, peramalan.

ABSTRACT

SANDRA BERLIANA PUTRI. Application of Long Short-Term Memory in Forecasting Non-Oil and Gas Export Value. Supervised by CYNTHIA KURNIAWATI HINDARTO of 1st SUPERVISOR and AGUS MOHAMAD SOLEH of 2nd SUPERVISOR.

Forecasting Indonesia's non-oil and gas export value is essential to support trade strategies and industrial policies. This study aims to predict non-oil and gas export values until December 2026 using the Long Short-Term Memory (LSTM) model. The data used are monthly observations from January 2005 to July 2025. The results show that the LSTM model effectively captures the patterns of non-oil and gas export values, with training and testing MAPE falling into the very good category and no indication of overfitting. Forecasts until December 2026 indicate a gradual declining trend in export values. These findings provide a foundation for the government and businesses to develop more adaptive and prediction-based export strategies.

Keywords: forecasting, hyperparameters, LSTM, MAPE, non-oil and gas exports.

LEMBAR PENGESAHAN

Judul : Penerapan Long Short-Term Memory dalam Peramalan Nilai Ekspor Nonmigas
Nama : Sandra Berliana Putri
NIM : G1401221021

Disetujui oleh

Pembimbing 1:
Cynthia Kurniawati Hindarto, S.S., M.E.

Pembimbing 2:
Dr. Agus Mohamad Soleh, S.Si., M.T.

Tanggal Pelaksanaan Magang:
1 September – 28 November 2025

PRAKATA

Puji dan syukur penulis panjatkan kepada Allah subhanahu wa ta'ala atas segala karunia-Nya sehingga karya ilmiah ini berhasil diselesaikan. Tema yang dipilih dalam penelitian yang dilaksanakan sejak bulan September 2025 sampai bulan Desember 2025 ini ialah analisis nilai ekspor nonmigas dengan judul "Penerapan Long Short-Term Memory dalam Peramalan Nilai Ekspor Nonmigas".

Penulisan karya ilmiah ini tidak luput atas bantuan dan dukungan berbagai pihak sehingga karya ilmiah ini dapat terselesaikan dengan baik. Oleh karena itu, penulis mengucapkan terima kasih kepada:

1. Bapak Dr. Bagus Sartono, M.Si. selaku Ketua Program Studi Statistika dan Sains Data, Sekolah Sains Data, Matematika, dan Informatika, Institut Pertanian Bogor.
2. Bapak Dr. Agus Mohamad Soleh, S.Si., M.Si. selaku dosen pembimbing magang.
3. Ibu Cynthia Kurniawati Hindarto, S.S., M.E. selaku pembimbing di Kementerian Perindustrian.
4. Seluruh rekan di Direktorat ASDIPI dan Ditjen KPAII, atas kerjasama, bantuan, dan komunikasi yang mendukung pelaksanaan tugas-tugas magang.
5. Keluarga besar statistika sebagai komunitas akademik dan tempat berdiskusi/bertukar informasi, serta teman-teman angkatan yang memberikan motivasi dan rasa kebersamaan.
6. Papa, mama, dan keluarga atas doa, dukungan moral dan material, serta kasih sayang yang tak pernah putus.

Semoga karya ilmiah ini bermanfaat bagi pihak yang membutuhkan dan bagi kemajuan ilmu pengetahuan.

Bogor, 5 Desember 2025

Sandra Berliana Putri

DAFTAR ISI

ABSTRAK ii
ABSTRACT ii
LEMBAR PENGESAHAN iii
PRAKATA iv
DAFTAR ISI v
DAFTAR TABEL vi
DAFTAR GAMBAR vi
I PENDAHULUAN 1
I.1 Latar Belakang 1
I.2 Tujuan 1
II TINJAUAN PUSTAKA 2
II. 1 *Long Short-Term Memory* (LSTM) 2
II.2 *Hyperparameters* 4
II.3 Early Stopping 5
III METODE 6
III. 1 Data 6
III.2 Prosedur Analisis Data 6
IV HASIL DAN PEMBAHASAN 7
IV.1 Analisis Eksplorasi Data 7
IV.2 Normalisasi Data 7
IV.3 Pembagian Data Latih dan Data Uji 8
IV.4 Pemodelan LSTM 8
IV. 5 Evaluasi Model 9
IV. 6 Peramalan hingga Desember 2026 10
V SIMPULAN DAN SARAN 11
V.1 Simpulan 11
V.2 Saran 11
DAFTAR PUSTAKA 12

DAFTAR TABEL

Tabel 1 Hyperparameter model LSTM 9
Tabel 2 Hasil MAPE kombinasi hyperparameter 9

DAFTAR GAMBAR

Gambar 1 Struktur 1 unit LSTM 2
Gambar 2 Fungsi aktivasi dalam LSTM 4
Gambar 3 Plot nilai ekspor nonmigas Indonesia 7
Gambar 4 Plot hasil normalisasi nilai ekspor nonmigas 8
Gambar 5 Plot pembagian data latih dan data uji 8
Gambar 6 Plot perbandingan data aktual dengan hasil prediksi 10
Gambar 7 Hasil peramalan Agustus 2025 hingga Desember 2026 10

I PENDAHULUAN

I.1 Latar Belakang

Perdagangan internasional yang meliputi ekspor dan impor merupakan salah satu kunci pertumbuhan ekonomi suatu negara. Pertumbuhan ekonomi di negara-negara maju didukung oleh pertumbuhan ekspor sehingga mampu menguasai pangsa ekspor dunia. Hal ini menunjukkan bahwa ekspor berperan penting dalam meningkatkan daya saing serta memperkuat struktur perekonomian suatu negara (Krugman & Obstfeld, 2009). Sejalan dengan hal tersebut, Indonesia juga menjadikan ekspor sebagai motor penggerak pertumbuhan ekonomi. Salah satu komponennya adalah ekspor nonmigas yang berkontribusi lebih dari 90% dalam setengah dekade terakhir (BPS, 2024).

Idealnya, nilai ekspor nonmigas Indonesia tumbuh stabil dan berkelanjutan sehingga menjadi landasan kuat bagi pemerintah maupun pelaku usaha dalam menyusun strategi perdagangan jangka menengah dan panjang. Namun, dalam praktiknya ekspor nonmigas dipengaruhi oleh berbagai faktor eksternal dan internal, seperti dinamika harga komoditas global, kondisi geopolitik, dan kebijakan perdagangan internasional. Faktor-faktor tersebut menyebabkan dinamika kompleks terhadap kinerja ekspor nonmigas. Oleh karena itu, upaya dalam meramalkan nilai ekspor nonmigas menjadi penting karena informasi tersebut dapat dijadikan dasar dalam perumusan kebijakan ekonomi maupun strategi bisnis.

Peramalan nilai ekspor nonmigas yang akurat memiliki arti penting bagi Direktorat Akses Sumber Daya Industri dan Promosi Internasional (ASDIPI). Sesuai dengan tugasnya dalam perumusan dan pelaksanaan kebijakan di bidang kerja sama akses industri pada sumber daya industri internasional, peningkatan akses dan tindak lanjut investasi usaha industri serta promosi industri internasional, dan penguatan rantai suplai global, ASDIPI memerlukan informasi peramalan nilai ekspor yang dapat diandalkan. Hasil peramalan ini dapat memberikan gambaran mengenai tren ekspor ke depan sehingga dapat dimanfaatkan sebagai bahan pertimbangan dalam penyusunan kebijakan.

Peramalan nilai ekspor nonmigas Indonesia sebelumnya telah dilakukan oleh Retnowardani dan Achmadin (2023) menggunakan ARIMA (*Autoregressive Moving Average*). Hasil penelitian menunjukkan bahwa ARIMA mampu memproyeksikan nilai ekspor nonmigas jangka pendek. Namun, ARIMA memiliki keterbatasan dalam menangkap pola data yang bersifat nonlinier dan berfluktuasi jangka panjang yang sering terjadi pada perdagangan internasional. Kemudian, penelitian oleh Magfirrah *et al*. (2023) yang membandingkan ARIMA dan LSTM dalam peramalan kecepatan angin maksimum di Kupang, NTT menemukan bahwa LSTM memberikan hasil lebih baik dibandingkan ARIMA. Dengan demikian, penelitian ini menerapkan metode LSTM untuk peramalan nilai ekspor nonmigas Indonesia dari Agustus 2025 hingga Desember 2026 sehingga penelitian ini diharapkan dapat memberikan alternatif model prediksi yang lebih akurat dan relevan bagi pengambilan keputusan, khususnya dalam mendukung perumusan kebijakan di bidang industri.

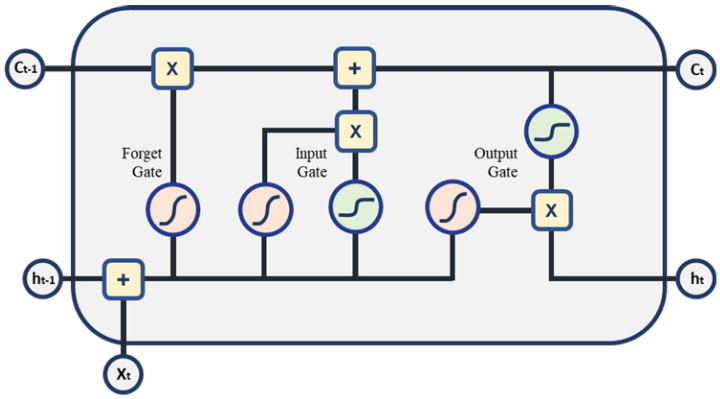
I.2 Tujuan

Penelitian ini bertujuan meramalkan nilai ekspor nonmigas Indonesia hingga Desember 2026.

II TINJAUAN PUSTAKA

II. 1 *Long Short-Term Memory* (LSTM)

Long Short-Term Memory (LSTM) berkembang dari *Recurrent Neural Network* (RNN), yang merupakan salah satu arsitektur dalam *deep learning*. Jaringan saraf (*neural network*) dalam *deep learning* terdiri dari banyak *layer* (lapisan) pemrosesan yang saling terhubung. Setiap *layer* berfungsi untuk mengekstraksi pola pada tingkat kompleksitas yang berbeda sehingga model mampu memahami struktur data yang kompleks (Goodfellow *et al*., 2016). Akibat memiliki koneksi berulang yang memungkinkan informasi dari langkah sebelumnya tetap tersimpan, RNN memiliki keterbatasan ketika mempelajari hubungan jangka panjang. Keterbatasan tersebut adalah *vanishing gradient* (keadaan nilai *gradient* yang mendekati atau bernilai 0) yang diatasi dengan LSTM (Julian dan Pribadi, 2021). LSTM menggunakan mekanisme *gate* (gerbang) yang mengatur informasi mana yang perlu dipertahankan, diperbarui, atau dilupakan (Brownlee, 2017). Dengan demikian, LSTM mampu memahami pola temporal yang panjang dengan lebih baik. Langkah-langkah perhitungan LSTM divisualisasikan pada Gambar 1 (Singhal, 2020). Adapun secara rinci algoritma LSTM adalah sebagai berikut (Hochreiter dan Schmidhuber, 1997).



Gambar 1 Struktur 1 unit LSTM

1. *Forget gate* ($\boldsymbol{f_t}$), berfungsi menghilangkan informasi yang kurang dibutuhkan menggunakan fungsi *sigmoid*. *Output* dari fungsi *sigmoid* mengindikasikan banyak informasi lama yang akan dihapus. Persamaan *forget gate* dapat dituliskan sebagai berikut.

$$\boldsymbol{f_t} = \sigma\left(W_f[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + b_f\right) \quad (1)$$

Keterangan:
σ : Fungsi aktivasi *sigmoid*
W_f : Bobot pada *forget gate*
$\boldsymbol{h_{t-1}}$: Vektor *hidden state* pada langkah ke t-1
$\boldsymbol{x_t}$: Vektor *input* x pada langkah ke t
b_f : Bias pada *forget gate*

2. *Input gate* ($\boldsymbol{i_t}$), berfungsi menentukan informasi akan ditambahkan atau tidak ke

dalam *cell state* menggunakan fungsi *sigmoid*. *Output* dari fungsi *sigmoid* mengindikasikan banyak informasi baru yang akan ditambahkan ke dalam *cell state*. Persamaan *input gate* dapat dituliskan sebagai berikut.

$$\boldsymbol{i_t} = \sigma(W_i[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + b_i) \quad (2)$$

Keterangan:
W_i : Bobot pada *input gate*
b_i : Bias pada *input gate*

Langkah ini dilanjutkan dengan membentuk kandidat vektor baru menggunakan fungsi *tanh* yang akan ditambahkan pada tahap *cell state*. Persamaannya adalah sebagai berikut.

$$\boldsymbol{c_t} = tanh(W_c[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + b_c) \quad (3)$$

Keterangan:
$tanh$: Fungsi aktivasi *tanh*
W_c : Bobot pada *cell state*
$\boldsymbol{c_t}$: *Cell state* pada langkah ke t
b_c : Bias pada *cell state*

3. *Cell state* ($\boldsymbol{c_t}$), berfungsi sebagai memori/ingatan untuk sebuah *layer*. $\boldsymbol{c_{t-1}}$ akan diperbaharui menjadi $\boldsymbol{c_t}$ melalui persamaan berikut.

$$\boldsymbol{c_t} = \boldsymbol{f_t}.\boldsymbol{c_{t-1}} + \boldsymbol{i_t}.\boldsymbol{c_t} \quad (4)$$

Keterangan:
$\boldsymbol{c_{t-1}}$: *Cell state* pada langkah ke t-1
$\boldsymbol{f_t}$: Nilai pada *forget gate* langkah ke t
$\boldsymbol{i_t}$: Nilai pada *input gate* langkah ke t

4. *Output gate* ($\boldsymbol{o_t}$), berfungsi untuk menentukan banyaknya informasi yang dihasilkan dari *cell state* baru ($\boldsymbol{c_t}$). *Output gate* terdiri dari dua jalur, yaitu jalur untuk memutuskan nilai yang dikeluarkan dengan menggunakan fungsi aktivasi *sigmoid* dan jalur untuk menyimpan nilai dengan menggunakan fungsi aktivasi *tanh*. Persamaan *output gate* adalah sebagai berikut.

$$\boldsymbol{o_t} = \sigma(W_o[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + b_o) \quad (5)$$

Keterangan:
W_o : Bobot pada *output gate*
b_o : Bias pada *output gate*

5. Nilai peramalan ke t+1, diperoleh dengan mengalikan hasil *output gate* dengan *tanh* dari *cell state* baru. Lalu, nilai tersebut akan digunakan pada perhitungan titik langkah selanjutnya. Persamaannya sebagai berikut.

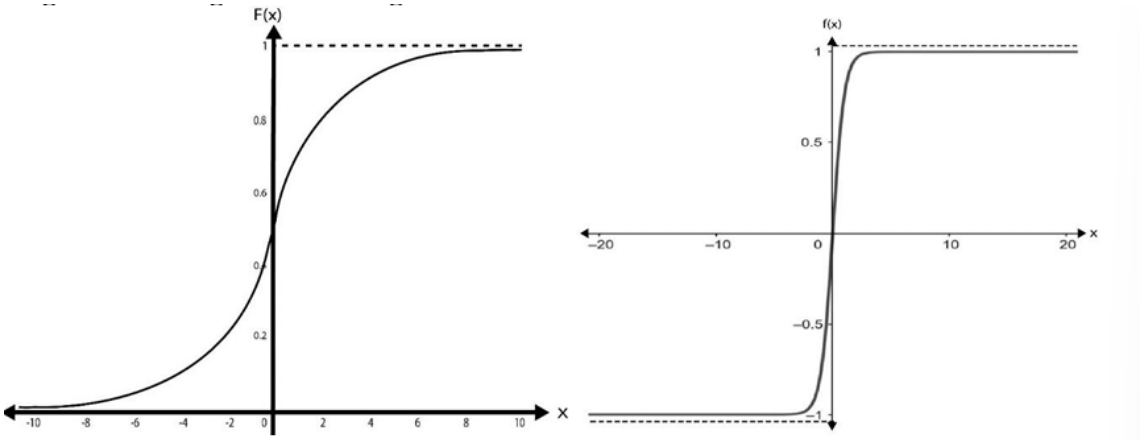
$$\boldsymbol{h_t} = \boldsymbol{o_c} * \tanh(\mathbf{c_t}) \quad (6)$$

Keterangan:
$\boldsymbol{h_t}$: Nilai peramalan langkah ke t+1
$\boldsymbol{o_c}$: Nilai pada *output gate*
$\boldsymbol{c_t}$: *Cell state* pada langkah ke t

LSTM menggunakan dua fungsi aktivasi, yaitu *sigmoid* dan *tanh*. Fungsi aktivasi *sigmoid* merubah nilai *input* ke interval [0,1] (Cybenko, 1989). Sementara fungsi aktivasi *tanh* merubah nilai *input* ke interval [-1,1] (Jarret *et al.* 2009). Grafik fungsi aktivasi tersebut disajikan pada Gambar 2 dengan persamaan sebagai berikut.

$$f_s(x) = \frac{1}{1+e^{-x}}, -\infty < x < \infty \tag{7}$$

$$f_t(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}, -\infty < x < \infty \tag{8}$$



(a) (b)

Gambar 2 Fungsi aktivasi dalam LSTM

II.2 *Hyperparameters*

Hyperparameter dalam *deep learning* adalah parameter yang harus ditetapkan sebelum proses pelatihan karena tidak diperbarui secara otomatis oleh model. Inisialisasi *hyperparameter* berpengaruh terhadap kecepatan pembelajaran dan kebaikan model yang dibuat (LeCun *et al.* 2015). *Hyperparameter* yang digunakan dalam penelitian adalah sebagai berikut.

II.2.1 *Time Steps*

Time steps adalah jumlah waktu atau observasi yang digunakan untuk meramalkan nilai selanjutnya. Nilai ini mengindikasikan seberapa panjang pola temporal yang dapat ditangkap oleh model. *Time steps* yang terlalu besar dapat menghasilkan model yang *underfitting*. Sementara, *time steps* yang terlalu kecil dapat menghasilkan model yang *overfitting* (Shen *et al*., 2021).

II.2.2 *Neuron*

Neuron merupakan unit *neural network* yang menerima *input*, melakukan perhitungan, dan menghasilkan *output* (Goofellow *et al.*, 2016). Setiap *neuron* memiliki bobot (*weight*) yang menentukan pengaruhnya terhadap *input* serta bias yang menentukan sensitivitasnya terhadap *input*. Pemilihan *neuron* yang tepat penting untuk melakukan pemodelan LSTM. Apabila terlalu kecil, LSTM tidak dapat melakukan fungsinya dengan baik dan apabila terlalu besar, LSTM akan

mengalami *overfitting* (Reimers dan Gurevych, 2017).

II.2.3 *Learning Rate*

Learning rate berfungsi untuk mengendalikan besar perubahan pada bobot dan bias setiap iterasi saat proses pelatihan. Hal ini berdampak pada kecepatan pembelajaran model pada data latih. Apabila *learning rate* terlalu besar, model dapat mengalami kegagalan mencapai konvergen dan melampaui nilai optimal. Sementara itu, jika terlalu kecil, proses pelatihan menjadi sangat lambat (Chollet, 2017).

II.2.4 *Epoch*

Epoch merupakan jumlah keseluruhan siklus pelatihan ketika model memproses seluruh data latih untuk memperbarui bobot dan bias (Chollet, 2017). Pada setiap *epochi*, model akan melakukan perhitungan kesalahan prediksi (*error*) dan menyesuaikan bobot berdasarkan *error* tersebut agar hasil prediksi semakin akurat. Semakin banyak *epoch* semakin banyak kesempatan model untuk belajar dari data tetapi dapat menyebabkan model *overfitting*. Sementara itu, apabila *epoch* terlalu kecil dapat membuat model tidak mampu menangkap pola data dengan benar (Abbasimehr *et al*., 2020).

II.2.5 *Batch Size*

Batch size adalah jumlah data latih yang diproses sekaligus sebelum model memperbarui bobotnya (Brownlee, 2017). Batch size yang besar membuat proses pelatihan lebih stabil dan cepat konvergen, tetapi model dapat terjebak pada minimum lokal. Sebaliknya, batch size yang kecil menghasilkan pembaruan bobot yang lebih acak, tetapi model dapat melewati nilai optimum yang lebih baik.

II.2.6 *Drop Out*

Dropout adalah teknik regularisasi yang menonaktifkan sejumlah neuron secara acak selama pelatihan. Tujuannya untuk mencegah model terlalu bergantung pada pola tertentu sehingga mengurangi risiko *overfitting*. Nilai *dropout* yang tepat membantu meningkatkan generalisasi model pada data baru (Srivastava *et al.*, 2014).

II.3 Early Stopping

Early stopping menghentikan pelatihan lebih awal ketika nilai *loss* tidak lagi menunjukkan perbaikan signifikan (Prechelt, 1997). Teknik ini mencegah model belajar terlalu lama dan mengalami *overfitting*. Dengan mengembalikan bobot terbaik selama pelatihan, *early stopping* memastikan model tetap optimal.

III METODE

III. 1 Data

Penelitian ini menggunakan data sekunder yang diperoleh dari *website* Badan Pusat Statistik (https://www.bps.go.id/). Data yang diambil berupa nilai ekspor nonmigas Indonesia setiap bulan dengan satuan juta US$. Periode data yang digunakan mencakup Januari 2005 hingga Juli 2025.

III.2 Prosedur Analisis Data

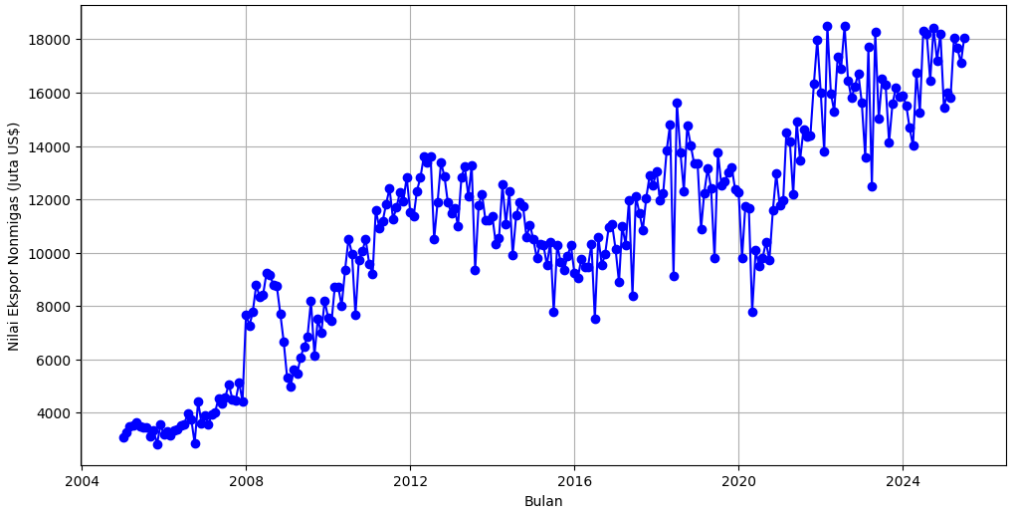
Analisis data menggunakan *software* Python. Tahapan analisisnya adalah sebagai berikut.

1. Melakukan eksplorasi data menggunakan *line chart* untuk mengetahui pola data dan statistika deskriptif untuk mengetahui struktur data.
2. Melakukan transformasi data menggunakan MinMaxScaler dengan rumus sebagai berikut (Goodfellow *et al*., 2016).
$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \tag{9}$$
3. Melakukan pembagian data menjadi 70% data latih dan 30% data uji.
4. Melakukan inisialisasi parameter LSTM yang dibangun dengan dua *hidden layer* dan satu *dense layer*, yaitu *neuron* (32), *dropout* (0,2), *epoch* (100), *time steps* (3 dan 6), *learning rate* (0,0001; 0,001; 0,01), dan *batch size* (16, 32, 64) serta melakukan pemilihan kombinasi *hyperparameter* terbaik berdasarkan performa model. Model juga dikompilasi menggunakan *optimizer* Adam (*Adaptive Moment Estimation*) dengan fungsi loss MAE (*Mean Absolute Error*).
5. Melakukan pembangunan model yang dilatih menggunakan data latih dengan *early stopping* untuk mencegah *overfitting*.
6. Melakukan prediksi terhadap data uji dan data latih.
7. Melakukan validasi model LSTM melalui plot perbandingan nilai aktual dan hasil prediksi serta menghitung MAPE (*Mean Absolute Percentage Error*) dengan rumus berikut (Chase, 2013).
$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| 100\% \tag{10}$$
8. Melakukan peramalan nilai ekspor nonmigas hingga Desember 2026.

IV HASIL DAN PEMBAHASAN

IV.1 Analisis Eksplorasi Data

Analisis eksplorasi data dilakukan guna memperoleh informasi mengenai pola data dan mengidentifikasi karakteristik data selama 247 bulan. Analisis eksplorasi ini menggunakan bantuan *line chart*. Berdasarkan Gambar 1, nilai ekspor nonmigas Indonesia menunjukkan tren naik disertai fluktuasi dari tahun 2005 hingga 2024. Pada periode $2005 - 2008$ nilai ekspor berada sekitar $3000 - 5000$ juta US$, lalu meningkat secara signifikan sejak 2008. Peningkatan terus terjadi hingga 2024 yang mencapai lebih 18000 juta US$. Secara umum, pola nilai ekspor ini menunjukkan adanya pertumbuhan jangka panjang positif.

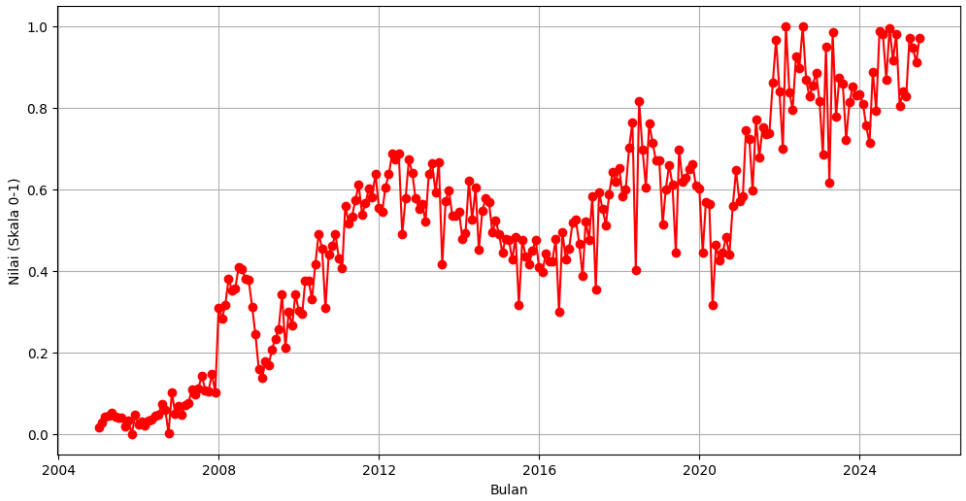


Gambar 3 Plot nilai ekspor nonmigas Indonesia

Analisis statistika deskriptif juga digunakan dalam mengeksplorasi data. Nilai ekspor nonmigas terendah selama periode penelitian sebesar 2829,8 juta US$ menunjukkan kondisi ekspor pada titik paling rendah di awal periode. Sebaliknya, nilai tertinggi mencapai 18509,1 juta US$ menunjukkan puncak pertumbuhan ekspor pada beberapa periode terakhir. Rata-rata nilai ekspor sebesar 10758,4 juta US$ menandakan bahwa secara umum ekspor nonmigas berada pada tingkat menengah dalam rentang data. Sementara itu, standar deviasi sebesar 4076,2 juta US$ mengindikasikan keragaman data dari rata-rata sehingga ekspor nonmigas mengalami fluktuasi dari bulan ke bulan.

IV.2 Normalisasi Data

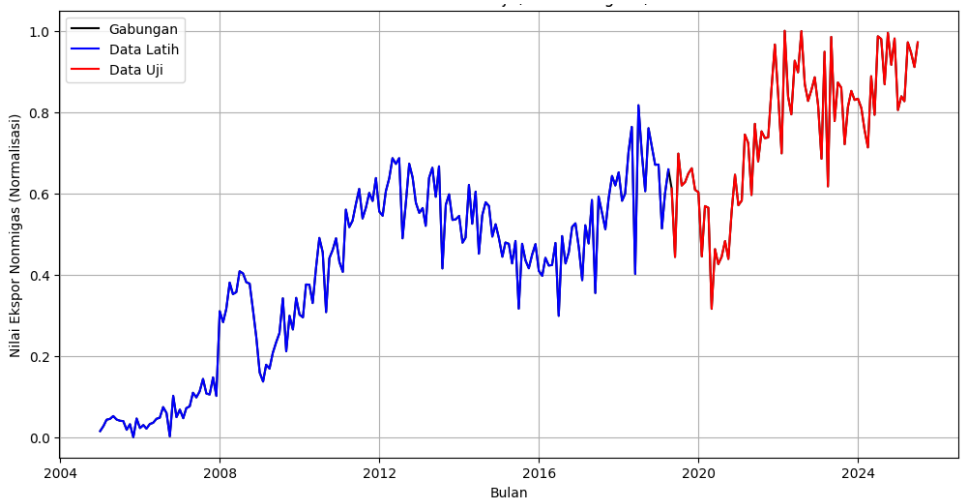
Normalisasi data pada penelitian ini menggunakan metode MinMaxScaler. Proses ini mengakibatkan rentang data aktual berubah menjadi 0 hingga 1. Normalisasi ini penting dalam mengoptimalkan model LSTM karena mampu menyeimbangkan skala data, mempercepat konvergensi model, serta mencegah dominasi nilai ekstrim (Brownlee, 2017). Hasil normalisasi ditampilkan pada Gambar 4. Terlihat bahwa pola pergerakan data setelah normalisasi tetap konsisten dengan data asli.



Gambar 4 Plot hasil normalisasi nilai ekspor nonmigas

IV.3 Pembagian Data Latih dan Data Uji

Proses berikutnya adalah membagi data menjadi dua bagian, yaitu data latih dan data uji. Proporsi antara data latih dan data uji adalah 70% dan 30%. Gambar 5 menunjukkan pembagian tersebut. Data latih mencakup periode Januari 2005 hingga April 2019. Sementara data uji mencakup periode Mei 2019 hingga Juli 2025. Data latih berfungsi dalam melatih model, sedangkan data uji berfungsi dalam mengevaluasi performa model dalam prediksi. Hal ini penting agar model tidak hanya mampu menyesuaikan diri terhadap data latih tetapi juga mampu melakukan generalisasi terhadap data yang belum pernah dilihat sebelumnya atau dengan kata lain menghindari *overfitting*.



Gambar 5 Plot pembagian data latih dan data uji

IV.4 Pemodelan LSTM

Pemodelan LSTM menggunakan arsitektur yang terdiri dari 2 *layer* LSTM serta 1 *layer dense*. Model tersebut dikompilasi dengan *optimizer* Adam karena kemampuannya dalam menggabungkan *Stochastic Gradient Descent* (SGD) dengan momentum serta RMSProp (menggunakan kuadrat gradien dalam menyesuaikan

kecepatan belajar) sehingga proses pelatihan lebih adaptif dan efisien. Lalu, fungsi *loss* yang digunakan adalah MAE. Selain arsitektur, penelitan ini juga menetapkan sejumlah *hyperparameter* yang disajikan dalam Tabel 1.

Tabel 1 *Hyperparameter* model LSTM

Karakteristik	Spesifikasi
Neuron	32
Dropout	0,2
Epoch	100
Time steps	3 dan 6
Learning rate	0,0001; 0,001; dan 0,01
Batch size	16, 32, dan 64

Proses *tuning hyperparameter* dilakukan secara manual untuk memperoleh kombinasi *hyperparameter* terbaik. Proses ini difokuskan pada tiga *hyperparameter*, yaitu *time steps, learning rate,* dan *batch size*. Sementara, nilai *hyperparameter* lainnya menggunakan nilai yang umum digunakan dalam LSTM. Semua kombinasi dievaluasi berdasarkan nilai MAPE dan model dilatih dengan *early stopping* untuk mencegah *overfitting* sehingga pelatihan berhenti ketika tidak terjadi perbaikan pada metrik evaluasi. Hasil evaluasi setiap kombinasi disajikan dalam Tabel 2. Berdasarkan Tabel 2, kombinasi *hyperparameter* terbaik dengan MAPE terkecil (8,22%) adalah *time steps* 3; *learning rate* 0,001; dan *batch size* 16. Model dibangun dan dilatih kembali menggunakan kombinasi tersebut.

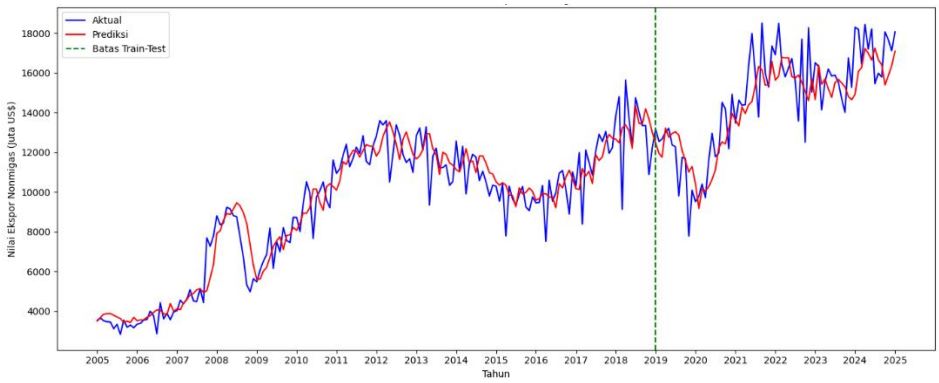
Tabel 2 Hasil MAPE kombinasi *hyperparameter*

Time steps	*Learning rate*	*Batch size*	MAPE (%)
3	0,0001	16	9,26
3	0,0001	32	10,43
3	0,0001	64	14,61
3	0,001	16	8,22
3	0,001	32	8,76
3	0,001	64	9,58
3	0,01	16	10,24
3	0,01	32	9,10
3	0,01	64	9,80
6	0,0001	16	9,57
6	0,0001	32	9,49
6	0,0001	64	11,46
6	0,001	16	9,67
6	0,001	32	11,23
6	0,001	64	10,50
6	0,01	16	12,37
6	0,01	32	11,40
6	0,01	64	10,93

IV. 5 Evaluasi Model

Prediksi nilai ekspor nonmigas dilakukan pada data latih dan data uji menggunakan

model LSTM dengan kombinasi *hyperparameter* terbaik. Kemudian, evaluasi model dilakukan dengan membandingkan hasil prediksi dan data aktual melalui *line chart*, seperti yang ditunjukkan Gambar 6. Terlihat bahwa hasil prediksi mengikuti tren dan fluktuasi data aktual dengan baik pada data latih maupun data uji, meskipun terdapat sedikit perbedaan pada beberapa puncak.

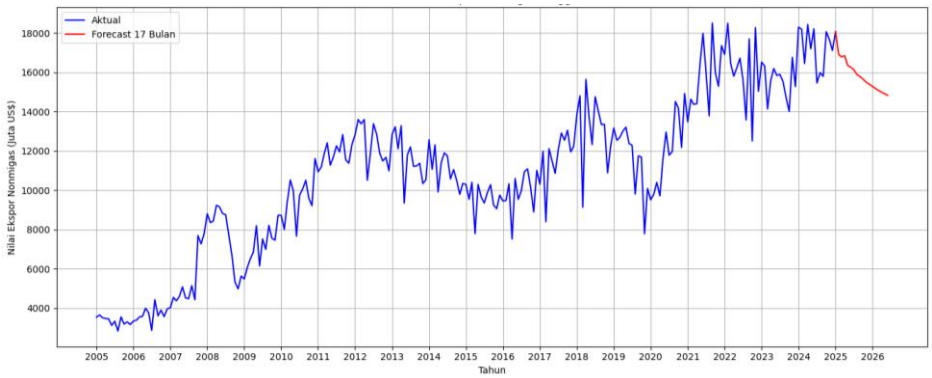


Gambar 6 Plot perbandingan data aktual dengan hasil prediksi

Evaluasi model juga dilakukan melalui perhitungan nilai MAPE. Hasil nilai MAPE data latih dan data uji, yaitu 9,46% dan 8,18%. Hasil menunjukkan nilai MAPE kedua dataset < 10% yang termasuk kategori sangat baik (Lewis, 1982). Hal ini mengindikasikan bahwa prediksi akurat dan konsisten pada data latih maupun uji, tanpa indikasi *overfitting*. Dengan demikian, hasil evaluasi model menegaskan bahwa model mampu menangkap pola nilai ekspor nonmigas dengan baik.

IV. 6 Peramalan hingga Desember 2026

Hasil peramalan nilai ekspor nonmigas Indonesia pada Gambar 7 menunjukkan tren penurunan bertahap hingga Desember 2026. Peramalan tersebut dilakukan dengan asumsi bahwa pola data tetap sama dan tidak ada intervensi pada titik waktu yang diramalkan. Model mempertimbangkan fluktuasi sebelumnya sehingga memberikan indikasi bahwa nilai ekspor nonmigas cenderung menurun dalam jangka pendek. Hasil ini dapat mendukung perencanaan strategi ekspor ke depan.



Gambar 7 Hasil peramalan Agustus 2025 hingga Desember 2026

V SIMPULAN DAN SARAN

V.1 Simpulan

Peramalan nilai ekspor nonmigas Indonesia dari bulan Agustus 2025 hingga Desember 2026 dapat dilakukan secara akurat menggunakan model LSTM yang dibangun dengan kombinasi *hyperparameter* terbaik, yaitu *time steps* 3; *learning rate* 0,001; dan *batch size* 16. Model tersebut mampu menangkap pola dari data yang terbukti melalui nilai MAPE dengan kategori sangat baik (< 10%) dan tidak menunjukkan indikasi terjadinya *overfitting*. Hasil peramalan menunjukkan tren penurunan nilai ekspor nonmigas secara bertahap hingga Desember 2026.

V.2 Saran

Penelitian selanjutnya disarankan melakukan *tuning hyperparameter* tambahan, mempertimbangkan faktor eksternal yang memengaruhi ekspor nonmigas, serta mengeksplorasi metode peramalan lain untuk mendukung penyusunan kebijakan berbasis prediksi yang lebih akurat.

DAFTAR PUSTAKA

Abbasimehra H, Shabani M, Yousefi M. 2020. An optimized model using LSTM network for demand forecasting. Computers & Industrial Engineering. 143(2020):1-13. doi: 10.1016/j.cie.2020.106435.

Bente AD, Rico-Hesse R. 2006. Model of dengue virus infection. Drug Discov Today Dis Models. 3(1):97-103. doi: 10.1016/j.ddmod. 2006.03.014.

Bernardo L, Izquierdo A, Prado I, Rosario D, Alvarez M, Santana E, Castro J, Martinez J, Rodriguez R, Morier L et al. 2008. Primary and secondary infections of Macaca fascicularis monkey with Asian and American genotypes of dengue virus 2. Clin Vaccine Immunol. 15(3): 439-446. doi: 10.1128/CVI.00208-07.

Brownlee J. 2017. Long Short-Term Memory Networks With Python.

Chase C. 2013. Demand-Driven Forecasting: A Structured Approach to Forecasting. New Jersey (US): John Wiley & Sons.

Chollet F. 2017. Deep Learning with Python. Ed ke-1st. USA: Manning Publications Co.

Cybenko G. 1989. Approximation by superpositions of a sigmoidal function. Math. Control. Signals Syst. 2(4):303-314. doi: 10.1007/BF02551274.

Goodfellow I, Bengio Y, Courville A. 2016. *Deep Learning*. The MIT Press.

Hochreiter S, Schmidhuber J. 1997. Long Short-Term Memory. Neural Comput. 9(8):1735–1780. doi:10.1162/neco.1997.9.8.1735.

Jarrett K, Kavukcuoglu K, Ranzato M, LeCun Y. 2009. What is the best multi-stage architecture for object recognition?. 2009 IEEE 12th International Conference on Computer Vision (ICCV). doi: 10.1109/ICCV.2009.5459469.

Julian R, Pribadi MR. 2021. Peramalan Harga Saham Pertambangan pada Bursa Efek Indonesia (BEI) Menggunakan Long Short-Term Memory (LSTM). JATISI (Jurnal Teknik Informatika dan Sistem Informasi). 8(3):1570–1580. doi:10.35957/jatisi.v8i3.1159.

Kochel TJ, Watts DM, Gonzalo AS, Ewing DF, Porter KR, Russell KL. 2005. Cross-serotype neutralization of dengue virus in Aotus nancyme monkeys. J Infect Dis. 191(6):1000-1004. doi:10.1086/427511.

LeCun Y, Bengio Y, Hinton G. 2015. Deep Learning. Nature. 521:436–444. doi:10.1038/nature14539.

Lewis CD. 1982. Industrial and Business Forecasting Methods. London (UK): Butterworth-Heinemann.

Onlamoon N, Noisakran S, Hsiao HM, Duncan A, Villinger F, Ansari AA, Perng GC. 2010. Dengue virus-induced hemorrhage in a nonhuman primate model. Blood. 115(9):1823-1834. doi:10.1182/blood-2009-09-241990.

Prechelt L. 1997. Early stopping–but when?. Di dalam: Orr GB, Müller KR, editor. Neural Networks: Tricks of the trade. Berlin (DE): Springer.

Reimers N, Gurevych I. 2017. Reporting score distributions makes a difference: performance study of lstm-networks for sequence taggin. Di dalam: 2017 Conference on Empirical Methods in Natural Language Processing. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing; 2017 Sep 07-11; Copenhagen, Denmark. Bogor: hlm 338-348; [diakses 2023 Okt 2023]. https://aclanthology.org/D17-1035.pdf

Shen L, Wei Z, Wang Y. 2021. Determining the Rolling Window Size of Deep Neural Network Based Models on Time Series Forecasting. J Phys Conf Ser. 2078:12011. doi:10.1088/1742-6596/2078/1/012011.

Singhal G. 2020. Introduction to LSTM Units in RNN. [Dipetik 2023 01 11]. Pluralsight. https://www.pluralsight.com/guides/introduction-to-lstm-units in-rnn

Srivastava N, Hinton G, Krizhevsky A, Sutskever I, Salakhutdinov R. 2014. Dropout: A simple way to prevent neural networks from overfitting. J Mach Learn Res. 15(1):1929–1958.

[WHO] World Health Organization. 2009. Dengue and dengue haemorrhagic fever [internet]. [diacu 2009 Mei 6]. Tersedia dari: http://www.who.int /mediacentre/ factsheets/ fs117/en/ index.html.